Projeto Laboratórios de Informática III

Fase 1

Projeto desenvolvido por

Daniel Pereira (A100545), Rui Lopes (A100643) e

Duarte Ribeiro (A100764)

Grupo 69

Licenciatura em Engenharia Informática

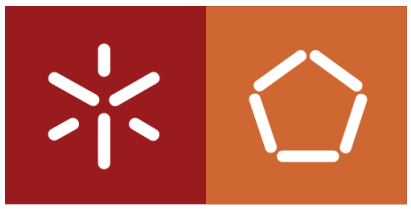

Universidade do Minho
Escola de Engenharia

Departamento de Informática

Universidade do Minho

Conteúdo

Capítulo 1

Introdução

Este projeto está a ser desenvolvido no âmbito da unidade curricular de Laboratórios de Informática III do ano 2022/2023, unidade esta que pretende dar a conhecer aos alunos os princípios fundamentais da Engenharia de Software - designadamente modularidade, reutilização, encapsulamento e abstração de dados. Foi-nos pedido para implementar uma base de dados em memória que armazene dados fornecidos pelos docentes, dados estes que se assemelham bastante à plataforma *Uber*, mundialmente conhecida.

O projeto está dividido em duas fases, e esta primeira fase consiste em implementar o *parsing* dos dados e o modo *batch*. Este modo consiste em executar várias *queries* sobre os dados de forma sequencial, estando esses pedidos armazenados num ficheiro de texto cujo caminho é recebido como argumento. Tomemos como exemplo a *query "top n utilizadores com maior distância viajada"*.

Assim sendo, este processo requer não só a leitura e interpretação dos dados dos ficheiros, como o seu armazenamento em estruturas de dados versáteis e de rápido acesso. Uma das vantagens deste projeto é termos acesso à *glib* - uma biblioteca que já possui implementações de várias estruturas úteis. Este grau de simplicidade e abstração convenceu-nos a usar esta biblioteca ao seu máximo potencial.

Capítulo 2

Desenvolvimento

Como era de esperar, este projeto não é fácil. Estamos ao nível universitário e, portanto, isso é expectável. Assim sendo, o nosso grupo planeou bastante antes de começar a escrever código. Somos apologistas de que é necessário uma fase de ponderação e planeamento de modo a ter uma visão clara e evitar refazer grandes partes de código devido a implementações ineficientes ou impráticas. Consideramos então esta fase um passo muito importante para o sucesso do que irá ser implementado. Começamos por imaginar uma arquitetura de como seria a ligação entre os diferentes módulos e a forma como iriam comunicar entre si. Isto é importante pois é fulcral que o encapsulamento e a modularidade estejam presentes em todo o projeto. A arquitetura a que chegamos foi bastante parecida à idealizada pelos docentes:

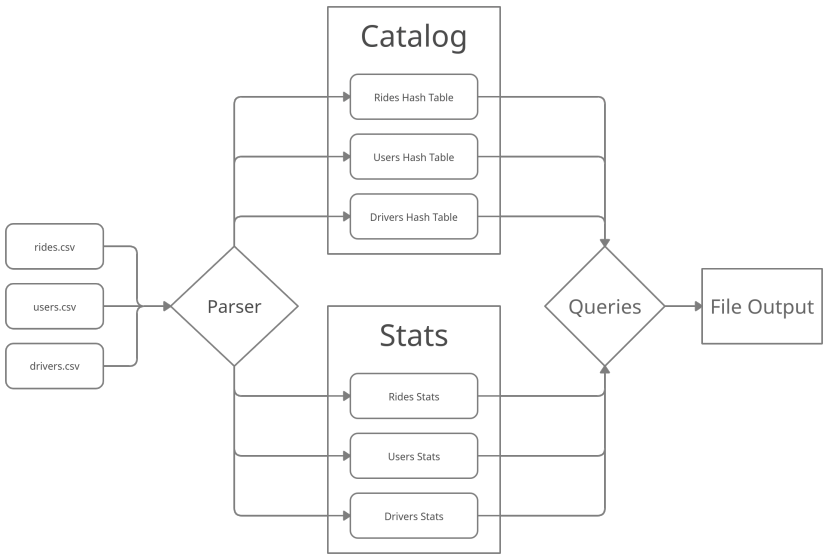

Figura 2.1: Diagrama da estrutura utilizada para o projeto

Depois disto chegou a hora, então, de partir para a ação. O desafio inicial foi perceber quais as estruturas ideais para armazenar todos os dados. Concluímos que *hash tables* eram o ideal para as estruturas principais, uma vez que apresentam tempo de acesso (*lookup*) constante. Criamos, portanto, três *hash tables* - uma para os *users*, uma para os *drivers* e outra para as *rides*. De modo a assemelharem-se ao máximo a uma base de dados, decidimos (seguindo a arquitetura descrita em cima) agrupá-las todas numa estrutura *mãe* apelidada de catálogo, onde cada uma das *hash tables* seria uma tabela da base de dados. Após isto foi necessário pensar no *parsing* dos dados. Desenvolvemos uma solução bastante simples, pois como o input se trata de um ficheiro CSV unicamente separado por pontos e vírgulas, criamos um parser geral que poderia ser chamado por outras funções noutro ficheiro que sabem assim utilizar o output do parser, contribuindo assim para a modularização do código. Definimos assim o módulo *parser* de forma ao mesmo não ter noção dos dados que está a receber - isto foi alcançado com recurso a *function pointers*, um recurso muito interessante e útil de C.

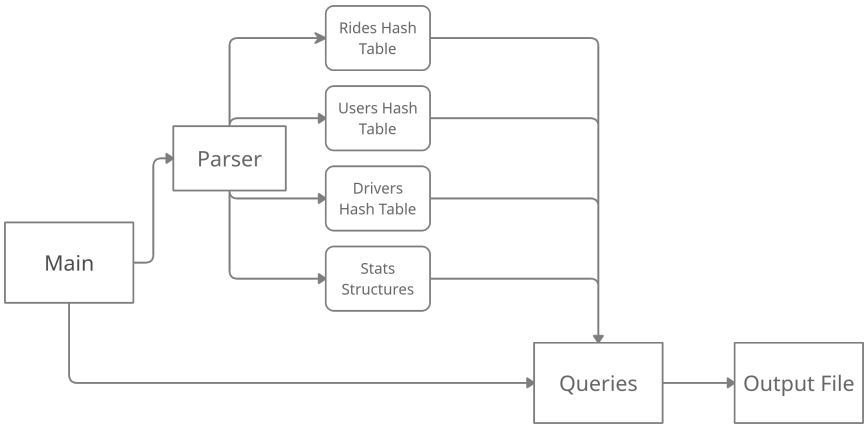

Figura 2.2: Diagrama do funcionamento do programa

Finalmente, de forma a finalizar o solicitado nesta primeira fase, optamos por escolher responder às três primeiras queries. Isto pois, no nosso ponto de vista, eram aquelas cuja implementação era mais simples.

Assim, passaremos a explicar a forma como implementamos cada uma das três:

Query 1: Esta primeira query consiste em *"listar o resumo de um perfil registado no serviço através do seu identificador"* - onde os identificadores são o *username* para os

users e o *id* para os *drivers*. Tomemos como exemplo as seguintes linhas:

1. *1 MiRibeiro33* (query destinada a um *user*)
2. *1 000000000024* (query destinada a um *driver*)

Assim sendo, o que fez mais sentido foi colocar estes identificadores como chave de cada uma das *hash tables* das entidades referidas, aproveitando assim o tal *lookup* constante. A partir daí, foi só construir o perfil da entidade solicitada. A maioria da informação que é impressa está diretamente armazenada nas *hash tables* dos utilizadores/drivers, mas o total gasto/auferido e o número de viagens realizadas têm de ser calculadas com base nos dados das *rides*. É aqui que as estruturas do módulo *stats* nos ajudam. Uma vez que guardamos todos estes valores numa estrutura auxiliar durante o *parsing* do ficheiro, precisamos apenas de acessá-los diretamente, trocando algum tempo de *startup* por muita poupança. Um *tradeoff* que é realizado em várias implementações do nosso projeto.

Query 2: A segunda query consiste em *"listar os n condutores com maior avaliação média"*, contando com vários critérios de desempate - em caso de empate em relação à avaliação média deverá aparecer o condutor com a viagem mais recente primeiro e, em caso de novo empate, deverá ser usado o *id* do condutor por ordem crescente. Decidimos implementar uma *linked list* que guarda as estatísticas de um condutor e que é atualizada durante a inserção das *rides*. Esta opção foi tomada porque a inserção e a ordenação (o algoritmo utilizado foi o `quick sort`) são mais rápidas numa *linked list*. Ainda assim, a mesma apresenta dois problemas: ocupa mais memória e apresenta baixa localidade espacial. Portanto, no futuro, iremos repensar a nossa escolha e, provavelmente, implementar um *array*.

Query 3: A terceira query consiste em *"listar os n utilizadores com maior distância viajada"*, contando novamente com vários critérios de desempate - em caso de empate em relação à distância viajada, deverá aparecer o utilizador com a viagem mais recente primeiro e em caso de novo empate, deverá ser usado o *username* do utilizador por ordem crescente. É de notar que esta query é bastante parecida à segunda e, portanto, após implementarmos a segunda, a implementação desta foi trivial. É de esperar também que a estrutura usada nesta se assemelhe à usada na segunda. Assim sendo, novamente, tomamos a opção de implementar uma *linked list*.

Capítulo 3

Dificuldades sentidas

Como já referido este trabalho não é fácil, o que implica que existiram e existirão muitas adversidades associadas. A maior dificuldade foi, sem dúvida alguma, a implementação cuidadosa do encapsulamento e da modularidade. Reconhecemos que estes pilares são fundamentais para um programa de qualidade, mas achamos que C não é a linguagem ideal para tal. Uma linguagem como Java, onde o paradigma é orientado a objetos, seria muito superior neste quesito. A facilidade de poder definir *atributos e métodos* públicos ou privados é um *must*. De qualquer das formas, acabamos por conseguir implementar os mesmos em grande parte do projeto. Ainda assim, consideramos que, por exemplo, a forma como atualizamos os dados dos *users* e dos *drivers* (ao mesmo tempo que lemos os dados das *rides*) pode, eventualmente, quebrar o encapsulamento. A realidade é que o tópico do encapsulamento é bastante extenso e complexo e, uma vez que é a primeira vez que o estamos a abordar, existirão, naturalmente, falhas. Fica aqui o dever de melhorar este aspeto na segunda fase.
Outra das dificuldades sentidas foi o facto de realizarmos mudanças atómicas no código sem perceber se estávamos a *partir* algo noutra parte do código. É de notar que um dos pontos levantados pelo encapsulamento e modularidade é a *garantia* de realizar estas mudanças sem grandes problemas associados - o que prova que, provavelmente, não implementamos os mesmos da forma mais eficaz. De qualquer das formas, uma maneira de contornar este problema foi criar testes unitários de apoio às funções criadas (testes estes executáveis a partir do comando `make test`). Apesar disto não ter peso aparente na nota do projeto pretendemos continuar a aplicá-los - já que demonstraram grande sucesso até agora.

Capítulo 4

Aspetos de desempenho

Neste capítulo iremos abordar alguns aspetos de desempenho relacionados a estas três primeiras queries que foram implementadas. Achamos que um dos aspetos mais importantes nos programas de hoje em dia é o tempo de execução de um programa. Tomemos como exemplo a seguinte lista de queries.

```
1 PetrPacheco
1 VaCosta
1 LeTavares103
1 000000002639
1 000000008561
1 000000004987
2 50
3 50
```

Portanto, seis queries do *tipo* 1 (três delas destinadas a *users* e três delas destinadas a *drivers*), uma query do *tipo* 2 e uma do *tipo* 3.
Em baixo, apresentamos os resultados do tempo de execução, sobre a lista dada, em três diferentes máquinas.

	Máquina 1	Máquina 2	Máquina 3
CPU	Intel Core i5-8300H	Apple M1	Ryzen 7 5800U
Cores/Threads	4/8	8/8	8/16
RAM	16GB DDR4 2666	16GB DDR4 2666	16GB LPDDR4 4200
Disco	512GB SSD M.2	512 GB SSD M.2	512GB SSD M.2
OS	Arch Linux	macOS Monterrey	Arch Linux
Tempo	1,635s	1,135s	1,580s

Nota: O tempo foi obtido realizando os testes 10 vezes, removendo o pior e o melhor resultado, e calculando a média dos 8 restantes.

Os tempos obtidos da máquina 1 e da 3 foram bastante semelhantes, devido a ambas usarem a mesma arquitetura base (x86) com frequência semelhante, tendo a máquina 3 uma pequena vantagem entre os dois, apesar do menor consumo de energia devido a ser um processador mais recente com um processo de fabricação menor, e, deste modo, mais eficiente (14 vs 7nm).

No entanto, nenhum dos dois se equipara à performance do MacBook com o processador M1 projetado na arquitetura ARM, cujo tempo de execução é aproximadamente 30% menor que ambos os computadores x86. Esta diferença deve-se à performance *single-core* ser muito superior neste processador e ao facto de ainda não termos suporte a *multi-threading* no programa, cuja implementação iria diminuir a disparidade, devido tanto às limitações energéticas e térmicas do MacBook, como à existência de muitas mais threads na máquina *Ryzen*. Deste modo, implementar *multi-threading* é algo que pretendemos no futuro.

Em termos de memória, foi atingido um pico de 370 *megabytes*, algo pouco significante tendo em conta o tamanho dos dados inseridos e bem abaixo do limite de 2GB pedido pelos docentes, mas é algo que trabalharemos para reduzir caso seja um problema com os ficheiros de maior dimensão da 2ª fase.

Capítulo 5

Conclusão

Em suma, apesar das várias dificuldades e novos desafios colocados por este projeto, pensamos estar à altura deste problema, e que no planeamento fizemos as decisões certas e por isso conseguimos construir uma boa base a partir da qual conseguimos expandir e alterar para as *queries* mais complexas da 2ª fase. Sendo assim, sentimo-nos preparados para concluir o projeto e melhorar ainda mais o que já fizemos até agora, sendo que o que já completamos ensinou-nos muito sobre alguns aspetos da programação que tínhamos abordado menos, como a modularização e encapsulamento, sendo estes princípios fundamentais para criar código sustentável e seguro, sendo assim essencial fomentar estes conhecimentos nos alunos.